

基于图像的三维模型重建

第2节 帧间运动估计



✓ 三角化(Triangulation)

- ✓ 直接线性变换法
- ✓ RANSAC鲁棒估计

✓ 3D-2D: PnP问题

- ✓ 直接线性变换法
- ✓ P3P/EPnP

✓ 捆绑调整Bundle Adjustment

已知**相机参数**和**匹配点**，恢复三维点的坐标

第 i 个相机投影矩阵：


$$P_i = K_i[R_i, t_i] = \begin{bmatrix} P_{i1} \\ P_{i2} \\ P_{i3} \end{bmatrix}$$

空间三维点坐标：

$$X = [x, y, z, 1]^T$$

对应在第 i 个视角中投影的图像坐标为：

$$x_i = [x_i, y_i, 1]^T$$



已知**相机参数**和**匹配点**，恢复三维点的坐标

根据投影方程可以得到：

$$d_i \mathbf{x}_i = \mathbf{P}_i \mathbf{X},$$

上述等式两侧同时叉乘 \mathbf{x}_i ：

$$\mathbf{x}_i \times (\mathbf{P}_i \mathbf{X}) = \mathbf{0}$$

其中，

$$\mathbf{x}_i = [x_i, y_i, 1]^T$$

$$\mathbf{P}_i \mathbf{X} = \begin{bmatrix} \mathbf{P}_{i1} \\ \mathbf{P}_{i2} \\ \mathbf{P}_{i3} \end{bmatrix} \mathbf{X} = \begin{bmatrix} \mathbf{P}_{i1} \mathbf{X} \\ \mathbf{P}_{i2} \mathbf{X} \\ \mathbf{P}_{i3} \mathbf{X} \end{bmatrix} \quad \text{3行1列}$$

根据向量叉积的运算，展开得

$$x_i (\mathbf{P}_{i3} \mathbf{X}) - \mathbf{P}_{i1} \mathbf{X} = \mathbf{0}$$

$$y_i (\mathbf{P}_{i3} \mathbf{X}) - \mathbf{P}_{i2} \mathbf{X} = \mathbf{0}$$

$$x_i (\mathbf{P}_{i2} \mathbf{X}) - y_i (\mathbf{P}_{i1} \mathbf{X}) = \mathbf{0}$$



$$\begin{bmatrix} x_i \mathbf{P}_{i3} - \mathbf{P}_{i1} \\ y_i \mathbf{P}_{i3} - \mathbf{P}_{i2} \end{bmatrix} \mathbf{X} = \mathbf{0}$$

注意：第3个方程与前两个方程线性相关。具体地，第三个等式等于第二个等式乘以 x_i 减第一个等式乘以 y_i 。

已知**相机参数**和**匹配点**，恢复三维点的坐标


1个观测点提供2个约束， X 有3个自由度，求解该方程至少2对点（从几何意义上解释，两条射线相交可确定空间中的一个三维点）。

$$AX = 0,$$

$$A = \begin{bmatrix} x_1 P_{13} - P_{11} \\ y_1 P_{13} - P_{12} \\ \dots \\ x_i P_{i3} - P_{i1} \\ y_i P_{i3} - P_{i2} \\ \dots \\ x_N P_{N3} - P_{N1} \\ y_N P_{N3} - P_{N2} \end{bmatrix}, N \geq 2$$

已知**相机参数**和**匹配点**，恢复三维点的坐标

宽基线（相机间的距离）求解更加稳定，在匹配成功的点对中选择宽基线中的匹配对进行三角化求解。



思考

如果存在外点（匹配点或姿态）的情况下，如何得到准确的三维点坐标？

基于RANSAC的三角化算法流程

- 1) 计算RANSAC采样次数，设置内点阈值（重投影误差）；
- 2) 随机采样一对视角，计算三维点坐标；
- 3) 计算每个视角中的重投影误差，统计内点个数；
- 4) 重复2), 3)直到满足采样次数，选择内点数最多的视角；
- 5) 利用所有内点重新计算三维点坐标。

Coding

完成task-2/task2-1_test_triangulation.cc中利用直接线性变化法求三维点坐标。

✓三角化(Triangulation)

- ✓ 直接线性变换法
- ✓ RANSAC鲁棒估计


✓ 3D-2D: PnP问题

- ✓ 直接线性变换法
- ✓ P3P/EPnP

✓ 捆绑调整Bundle Adjustment

3D-2D: PnP问题-PnP


已知**三维点**和**对应二维点**，求解相机内外参数




已知3D点坐标



对应的2D点坐标 (紫色)
以及重投影点 (红色)



优化后的人脸姿态实现的AR效果



给定内参矩阵 K

外参矩阵 $R, t?$

3D-2D: PnP问题-直接线性变换法

已知**三维点**和**对应二维点**，求解相机内外参数

$$s \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = K[R, t]X = K[R, t] \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix} = \begin{bmatrix} T_{11} & T_{12} & T_{13} & T_{14} \\ T_{21} & T_{22} & T_{23} & T_{24} \\ T_{31} & T_{32} & T_{33} & T_{34} \end{bmatrix} \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix} = \begin{pmatrix} r_1^T \\ r_2^T \\ r_3^T \end{pmatrix} X$$

$$u = \frac{T_{11}X + T_{12}Y + T_{13}Z + T_{14}}{T_{31}X + T_{32}Y + T_{33}Z + T_{34}} = \frac{\mathbf{r}_1^T \mathbf{X}}{\mathbf{r}_3^T \mathbf{X}} = \frac{\mathbf{X}^T \mathbf{r}_1}{\mathbf{X}^T \mathbf{r}_3} \quad \text{标量}$$

$$v = \frac{T_{21}X + T_{22}Y + T_{23}Z + T_{24}}{T_{31}X + T_{32}Y + T_{33}Z + T_{34}} = \frac{\mathbf{r}_2^T \mathbf{X}}{\mathbf{r}_3^T \mathbf{X}} = \frac{\mathbf{X}^T \mathbf{r}_2}{\mathbf{X}^T \mathbf{r}_3}$$

$$\mathbf{X}^T \mathbf{r}_1 - \mathbf{X}^T \mathbf{r}_3 u = 0$$

$$\mathbf{X}^T \mathbf{r}_2 - \mathbf{X}^T \mathbf{r}_3 v = 0$$

已知**三维点**和**对应二维点**，求解相机内外参数

$$\begin{pmatrix} X_1^T & 0 & -uX_1^T \\ 0 & X_1^T & -vX_1^T \\ \vdots & \vdots & \vdots \\ X_N^T & 0 & -uX_N^T \\ 0 & X_N^T & -vX_N^T \end{pmatrix} \begin{pmatrix} r_1 \\ r_2 \\ r_3 \end{pmatrix} = \mathbf{0}$$

一共12个未知参数，每对3D-2D对应点提供2个线性约束，因此共需要至少**6对3D-2D对应点**，才可求得 r_1, r_2, r_3 ，即求得矩阵 $T = [KR, Kt]$

求解内参及旋转

已知 $T(:, 1:3) = KR$ ，且内参矩阵 K 为上三角矩阵， R 为正交矩阵。

对矩阵 $T(:, 1:3)^{-1}$ 进行QR分解，分别得到 R^{-1} 以及 K^{-1} ，进而得到内参矩阵 K 以及旋转矩阵 R 。

求解平移

已知 $T(:, 4) = Kt$ ，以及内参矩阵 K ，可得平移向量 t 。

A Novel Parametrization of the Perspective-Three-Point Problem for a Direct Computation of Absolute Camera Position and Orientation

Laurent Kneip
laurent.kneip@mavt.ethz.ch

Davide Scaramuzza
davide.scaramuzza@mavt.ethz.ch

Roland Siegwart
rsiegwart@ethz.ch

Autonomous Systems Lab, ETH Zurich

- P3p: 从3对3D-2D的对应点中确定相机的朝向和位置
- 通常会产生4对解，需要用第4对匹配关系确定
- 一般的求解思路是首先计算点在相机中的3D坐标，然后通过ICP的方式计算相机姿态
- Kneip是一种close-form的P3p求解方式，主要思想是引入相机和世界坐标系的中间坐标系计算它们之间的相对姿态和位置来得到相机的姿态，Kneip的优势是求解稳定、速度快

创建新的相机坐标系

世界坐标系 (O, X, Y, Z)

世界坐标系中的3个点 P_1, P_2, P_3

相机坐标系 ν 中的单位向量 $\vec{f}_1, \vec{f}_2, \vec{f}_3$

创建新的相机坐标系: $\tau = (C, \vec{t}_x, \vec{t}_y, \vec{t}_z)$

$$\begin{aligned}\vec{t}_x &= \vec{f}_1 \\ \vec{t}_z &= \frac{\vec{f}_1 \times \vec{f}_2}{\|\vec{f}_1 \times \vec{f}_2\|} \\ \vec{t}_y &= \vec{t}_z \times \vec{t}_x.\end{aligned}$$

通过旋转变换 $T = [\vec{t}_x, \vec{t}_y, \vec{t}_z]^T$ 将单位向量由 ν 转换到 τ

$$\vec{f}_i^\tau = T \cdot \vec{f}_i$$




Figure 1. Synopsis of the problem.

创建新的世界坐标系

创建新的世界坐标系 $\eta = (P_1, \vec{n}_x, \vec{n}_y, \vec{n}_z)$

$$\begin{aligned}\vec{n}_x &= \frac{\overrightarrow{P_1 P_2}}{\|\overrightarrow{P_1 P_2}\|} \\ \vec{n}_z &= \frac{\vec{n}_x \times \overrightarrow{P_1 P_3}}{\|\vec{n}_x \times \overrightarrow{P_1 P_3}\|} \\ \vec{n}_y &= \vec{n}_z \times \vec{n}_x.\end{aligned}$$

通过旋转矩阵 $N = [\vec{n}_x, \vec{n}_y, \vec{n}_z]^T$ 将世界坐标系的点转换到 η 坐标系下

$$P_i^\eta = N \cdot (P_i - P_1).$$




Figure 2. Illustration of the intermediate camera frame $\tau = (C, \vec{t}_x, \vec{t}_y, \vec{t}_z)$ and the intermediate world frame $\eta = (P_1, \vec{n}_x, \vec{n}_y, \vec{n}_z)$.

相机中心在平面中的表达

P_1, P_2, C 三个点构成一个平面 Π 定义 $\beta = \vec{f}_1 \cdot \vec{f}_2$

根据几何约束 $\frac{\|\vec{CP}_1\|}{d_{12}} = \frac{\sin(\pi - \alpha - \beta)}{\sin \beta}$

相机中心 C 在平面 Π 中可以表达为

$$\begin{aligned} C^{\Pi}(\alpha) &= \begin{pmatrix} \cos \alpha \cdot \|\vec{CP}_1\| \\ \sin \alpha \cdot \|\vec{CP}_1\| \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} d_{12} \cos \alpha \sin(\alpha + \beta) \sin^{-1} \beta \\ d_{12} \sin \alpha \sin(\alpha + \beta) \sin^{-1} \beta \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} d_{12} \cos \alpha (\sin \alpha \cot \beta + \cos \alpha) \\ d_{12} \sin \alpha (\sin \alpha \cot \beta + \cos \alpha) \\ 0 \end{pmatrix} \\ \Rightarrow C^{\Pi}(\alpha) &= \begin{pmatrix} d_{12} \cos \alpha (\sin \alpha \cdot b + \cos \alpha) \\ d_{12} \sin \alpha (\sin \alpha \cdot b + \cos \alpha) \\ 0 \end{pmatrix} \end{aligned}$$




Figure 3. Semi-plane Π containing the triangle (P_1, P_2, C) . The blue trajectory indicates the possible locations of the camera centre C depending on the free parameter α , and the fixed parameters d_{12} and β .

相机中心和姿态在新建世界坐标系中表达

新建相机坐标系 τ 的基向量在平面中 Π 的表达为

$$\vec{t}_x^\Pi = (-\cos \alpha, -\sin \alpha, 0)^T,$$

$$\vec{t}_y^\Pi = (\sin \alpha, -\cos \alpha, 0)^T$$

$$\vec{t}_z^\Pi = (0, 0, 1)^T.$$

绕 \vec{n}_x 的旋转矩阵可以表达为

$$R_\theta = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos \theta & -\sin \theta \\ 0 & \sin \theta & \cos \theta \end{pmatrix}$$

相机在中心 C 在坐标系 η 的表达为

$$\begin{aligned} C^\eta(\alpha, \theta) &= R_\theta \cdot C^\Pi \\ &= \begin{pmatrix} d_{12} \cos \alpha (\sin \alpha \cdot b + \cos \alpha) \\ d_{12} \sin \alpha \cos \theta (\sin \alpha \cdot b + \cos \alpha) \\ d_{12} \sin \alpha \sin \theta (\sin \alpha \cdot b + \cos \alpha) \end{pmatrix} \end{aligned}$$




Figure 4. Rotation of the plane Π around \vec{n}_x by the angle θ .

η 到 τ 的旋转表达为

$$\begin{aligned} Q(\alpha, \theta) &= [R_\theta \cdot (\vec{t}_x^\Pi \vec{t}_y^\Pi \vec{t}_z^\Pi)]^T \\ &= \begin{pmatrix} -\cos \alpha & -\sin \alpha \cos \theta & -\sin \alpha \sin \theta \\ \sin \alpha & -\cos \alpha \cos \theta & -\cos \alpha \sin \theta \\ 0 & -\sin \theta & \cos \theta \end{pmatrix} \end{aligned}$$

将第3个点从新建世界坐标系 η 转换到新建相机坐标系 τ 中

已知 $P_3^\eta = (p_1, p_2, 0)^T$

$$P_3^\tau = Q(\alpha, \theta) \cdot (P_3^\eta - C^\eta(\alpha, \theta))$$

$$= \begin{pmatrix} -\cos \alpha \cdot p_1 - \sin \alpha \cos \theta \cdot p_2 + d_{12}(\sin \alpha \cdot b + \cos \alpha) \\ \sin \alpha \cdot p_1 - \cos \alpha \cos \theta \cdot p_2 \\ -\sin \theta \cdot p_2 \end{pmatrix}$$

定义 $\phi_1 = \frac{f_{3,x}^\tau}{f_{3,z}^\tau}$ $\phi_2 = \frac{f_{3,y}^\tau}{f_{3,z}^\tau}$

$$\begin{cases} \phi_1 = \frac{P_{3,x}^\tau}{P_{3,z}^\tau} \\ \phi_2 = \frac{P_{3,y}^\tau}{P_{3,z}^\tau} \end{cases}$$

$$\Leftrightarrow \begin{cases} \phi_1 = \frac{-\cos \alpha \cdot p_1 - \sin \alpha \cos \theta \cdot p_2 + d_{12}(\sin \alpha \cdot b + \cos \alpha)}{-\sin \theta \cdot p_2} \\ \phi_2 = \frac{\sin \alpha \cdot p_1 - \cos \alpha \cos \theta \cdot p_2}{-\sin \theta \cdot p_2} \end{cases}$$

$$\Leftrightarrow \begin{cases} \frac{\sin \theta}{\sin \alpha} p_2 = \frac{-\cot \alpha \cdot p_1 - \cos \theta \cdot p_2 + d_{12}(b + \cot \alpha)}{-\phi_1} \\ \frac{\sin \theta}{\sin \alpha} p_2 = \frac{p_1 - \cot \alpha \cos \theta \cdot p_2}{-\phi_2} \end{cases}$$

$$\Rightarrow \cot \alpha = \frac{\frac{\phi_1}{\phi_2} p_1 + \cos \theta \cdot p_2 - d_{12} \cdot b}{\frac{\phi_1}{\phi_2} \cos \theta \cdot p_2 - p_1 + d_{12}}$$



可以得到

$$\phi_2 = \frac{P_{3,y}^\tau}{P_{3,z}^\tau}$$

$$\Leftrightarrow \sin^2 \theta \cdot f_2^2 p_2^2 = \sin^2 \alpha (p_1 - \cot \alpha \cos \theta \cdot p_2)^2$$

$$\Leftrightarrow (1 - \cos^2 \theta)(1 + \cot^2 \alpha) f_2^2 p_2^2 = p_1^2 - 2 \cot \alpha \cos \theta \cdot p_1 p_2 + \cot^2 \alpha \cos^2 \theta \cdot p_2^2$$

构建四次方程

最终可以得到一个关于 $\cos \theta$ 的四次方程

$$a_4 \cdot \cos^4 \theta + a_3 \cdot \cos^3 \theta + a_2 \cdot \cos^2 \theta + a_1 \cdot \cos \theta + a_0 = 0$$

其中

$$\begin{aligned} a_4 &= -\phi_2^2 p_2^4 - \phi_1^2 p_2^4 - p_2^4 \\ a_3 &= 2p_2^3 d_{12} b + 2\phi_2^2 p_2^3 d_{12} b - 2\phi_1 \phi_2 p_2^3 d_{12} \\ a_2 &= -\phi_2^2 p_1^2 p_2^2 - \phi_2^2 p_2^2 d_{12}^2 b^2 - \phi_2^2 p_2^2 d_{12}^2 + \phi_2^2 p_2^4 \\ &\quad + \phi_1^2 p_2^4 + 2p_1 p_2^2 d_{12} + 2\phi_1 \phi_2 p_1 p_2^2 d_{12} b \\ &\quad - \phi_1^2 p_1^2 p_2^2 + 2\phi_2^2 p_1 p_2^2 d_{12} - p_2^2 d_{12}^2 b^2 - 2p_1^2 p_2^2 \\ a_1 &= 2p_1^2 p_2 d_{12} b + 2\phi_1 \phi_2 p_2^3 d_{12} \\ &\quad - 2\phi_2^2 p_2^3 d_{12} b - 2p_1 p_2 d_{12}^2 b \\ a_0 &= -2\phi_1 \phi_2 p_1 p_2^2 d_{12} b + \phi_2^2 p_2^2 d_{12}^2 + 2p_1^3 d_{12} \\ &\quad - p_1^2 d_{12}^2 + \phi_2^2 p_1^2 p_2^2 - p_1^4 - 2\phi_2^2 p_1 p_2^2 d_{12} \\ &\quad + \phi_1^2 p_1^2 p_2^2 + \phi_2^2 p_2^2 d_{12}^2 b^2. \end{aligned}$$

每一个 $\cos \theta$ 对应一个 $\cot \alpha$ 一共可以得到4组解

$$C = P_1 + N^T \cdot C^n$$

$$R = N^T \cdot Q^T \cdot T.$$

通过第4个点可以选择出正确的解

基于RANSAC的Kneip算法流程

- 1) 计算RANSAC采样次数, 设置内点阈值 (重投影误差) ;
- 2) 随机采样三对3D-2D对应点, 计算相机的姿态;
- 3) 计算每个视角中的重投影误差, 统计内点个数;
- 4) 重复2), 3)直到满足采样次数, 选择内点数最多的相机姿态;

P3P法：需要4对不共面的点 求出2D点在当前相机坐标系中的3D点，然后进行3D-3D的姿态求解

参考资料1: <https://www.cnblogs.com/mafuqiang/p/8302663.html>

[Complete Solution Classification for the Perspective-Three-Point Problem](#)

参考资料2: [A novel parametrization of the perspective-three-point problem for a direct computation of absolute camera position and orientation](#)

参考资料3: 《视觉SLAM十四讲》第7.7.2节

ePnP法：需要(≥ 4 不共面或者3对共面) 点进行求解

参考资料1: <https://www.cnblogs.com/jian-li/p/5689122.html>

参考资料2: [EPnP: Efficient Perspective-n-Point Camera Pose Estimation](#)

Coding

完成task-2/task2-2_test_p3p_kneip.cc代码，掌握算法流程。

完成task-2/task2-2_test_p3p_ransac.cc代码，掌握算法流程。

✓三角化(Triangulation)

- ✓ 直接线性变换法
- ✓ RANSAC鲁棒估计

✓ 3D-2D: PnP问题

- ✓ 直接线性变换法
- ✓ P3P/EPnP

✓ 捆绑调整Bundle Adjustment

问题阐述：同时对三维点位置和相机参数进行非线性优化。

$\chi_{ij} = 1$ 表示第 i 个点在第 j 个相机中可见；

$\chi_{ij} = 0$ 表示第 i 个点在第 j 个相机中不可见；


$\mathbf{X}_i = (X_i, Y_i, Z_i)^T$ 表示三维点世界坐标系中的坐标；

\mathbf{C}_j 表示第 j 个相机的内参数以及世界坐标系与第 j 个相机的外参数

$\hat{\mathbf{u}}_{ij}$ 表示第 i 个点在第 j 个相机中的观测点；

\mathbf{u}_{ij} 表示第 i 个点在第 j 个相机中的投影点；

$$g(\theta) = \frac{1}{2} \sum_i^n \sum_j^m \chi_{ij} \left\| \hat{\mathbf{u}}_{ij} - \mathbf{u}_{ij}(\mathbf{C}_j, \mathbf{X}_i) \right\|^2 = \frac{1}{2} \sum_i^n \sum_j^m \chi_{ij} e_{ij}$$



其中, $\theta = (\mathbf{C}_1, \dots, \mathbf{C}_m, \mathbf{X}_1, \dots, \mathbf{X}_n)$ 为待优化的量, $\theta \in \mathbb{R}^{9m \times 3n}$ 高维空间的非线性优化。

无约束非线性最小优化问题

$$\min g(\boldsymbol{\theta}) = \min \frac{1}{2} \|\boldsymbol{x} - f(\boldsymbol{\theta})\|^2, \boldsymbol{\theta} \in \boldsymbol{R}^n$$

上述问题的最优解通常是指它的**局部最优解**，对初始值较为敏感，因此需要一个较好的初始值。

最速下降法--假设函数一阶可微

假设 $g(\theta)$ 在 θ_t 处可微，则它在 θ_t 处有Taylor展开式(略去高阶不计)：

$$g(\theta) = g(\theta_t) + (\nabla g(\theta_t))^T \delta\theta,$$

其中 $\theta = \theta_t + \delta\theta$

- 当 $(\nabla g(\theta_t))^T \delta\theta < 0$ 时可保证 $g(\theta)$ 的值是在下降；
- 当 $\delta\theta$ 方向取梯度反方向时，可达到最快的下降速度。

为什么当 $\delta\theta$ 方向取梯度反方向时，达到最快的下降速度？

$$\Delta g = g(\theta) - g(\theta_t) = (\nabla g(\theta_t))^T \delta\theta,$$


可见，函数变化量 Δg 为向量 $\nabla g(\theta_t)$ 与 $\delta\theta$ 的内积，根据向量内积的计算公式，得：

$$\Delta g = \|\nabla g(\theta_t)\| \|\delta\theta\| \cos\alpha,$$

因为 $\cos\alpha \in [-1, 1]$ ，当且仅当 $\delta\theta$ 的方向取梯度反方向时，函数值下降最快。当然这只是一个方向，通常我们还需要指定一个步长 λ 。

最速下降法--算法流程

- 1) 给定初始点 θ_0 , 终止控制函数 $\epsilon > 0$ 和步长 λ , 令 $t = 0$;
- 2) 计算 $\nabla g(\theta_t)$, 若 $\|\nabla g(\theta_t)\| \leq \epsilon$, 停止迭代, 输出 θ_t , 否则进行下一步;
- 3) 取 $\theta_{t+1} = \theta_t - \lambda \nabla g(\theta_t)$, $t = t + 1$ 转第2)步。



越接近极值速度越慢

牛顿法--假设函数二阶可微

假设 $g(\theta)$ 在 θ_t 处二阶可微，且假定二阶导数 $\nabla^2 g(\theta)$ 总是正定的，则它在 θ_t 处以 $g(\theta)$ 的二阶近似函数 $Q(\theta)$ 的极小值点作为下一次迭代点 θ_{t+1} 。

$$Q(\theta) = g(\theta_t) + (\nabla g(\theta_t))^T \delta\theta + \frac{1}{2} \delta^T \theta \nabla^2 g(\theta_t) \delta\theta, \quad \theta = \theta_t + \delta\theta$$


上式对 $\delta\theta$ 求梯度并令其等于0，可以得到：

$$\nabla Q(\theta) = \nabla g(\theta_t) + \nabla^2 g(\theta_t) \delta\theta = 0$$

$$\delta\theta = -(\nabla^2 g(\theta_t))^{-1} \nabla g(\theta_t)$$

牛顿法--算法流程

- 1) 给定初始点 θ_0 , 终止控制函数 $\epsilon > 0$ 和步长 $\lambda = 1$, 令 $t = 0$;
- 2) 计算 $\nabla g(\theta_t)$, 若 $\|\nabla g(\theta_t)\| \leq \epsilon$, 停止迭代, 输出 θ_t , 否则进行下一步;
- 3) 取 $\theta_{t+1} = \theta_t - (\nabla^2 g(\theta_t))^{-1} \nabla g(\theta_t)$, $t = t + 1$ 转第2)步。



— 牛顿法

— 最速下降法

牛顿法—优点与缺点

1) 速度快

最速下降法是局部平面拟合，牛顿法是局部二次曲面拟合；

2) 计算量大

需要计算和保存二阶Hessian矩阵的逆矩阵；

3) 要求初始点离最优点较近，否则无法保证收敛，甚至无法保证下降性。

Levenberg-Marquardt法--原理与优势

原理：是一种“信赖域”的方法，当收敛速度较快时，增大信赖域，使算法趋向于牛顿法；当收敛速度较慢时，减小信赖域，使算法趋向于最速下降法。

优势：

- 速度快，只用到一阶矩阵；
- 对初始值有一定鲁棒性，可以在距离初始值较远处得到最优解。

Levenberg-Marquardt法--实现

$$g(\boldsymbol{\theta}) = \frac{1}{2} \|\mathbf{x} - f(\boldsymbol{\theta})\|^2, \boldsymbol{\theta} \in \mathbb{R}^n$$

可得 $\nabla g(\boldsymbol{\theta}_t) = -J^T(\boldsymbol{\theta}_t)(\mathbf{x} - f(\boldsymbol{\theta}_t))$, 其中 $J(\boldsymbol{\theta}_t) = \nabla f(\boldsymbol{\theta}_t)$ 。

$$\nabla^2 g(\boldsymbol{\theta}_t) \delta \boldsymbol{\theta} = -\nabla g(\boldsymbol{\theta}_t)$$

将上述公式中的 $\nabla^2 g(\boldsymbol{\theta}_t)$ 替换成 $J^T(\boldsymbol{\theta}_t)J(\boldsymbol{\theta}_t) + \frac{1}{\lambda}I$ (λ 为信赖域半径), 可得

$$(J^T(\boldsymbol{\theta}_t)J(\boldsymbol{\theta}_t) + \frac{1}{\lambda}I)\delta \boldsymbol{\theta} = J^T(\boldsymbol{\theta}_t)(\mathbf{x} - f(\boldsymbol{\theta}_t))$$

增量正规方程

当 λ 趋向于无穷大时, $J^T(\boldsymbol{\theta}_t)J(\boldsymbol{\theta}_t)\delta \boldsymbol{\theta} = -\nabla g(\boldsymbol{\theta}_t)$;

当 λ 趋向于零时, $\delta \boldsymbol{\theta} = -\nabla g(\boldsymbol{\theta}_t)$ 。

Levenberg-Marquardt法--算法流程

1. $t = 0$ 时, 选取初始点 θ_0 , 终止控制常数 ε , 令 $e^0 = \|\mathbf{x} - f(\theta_0)\|^2$, $\lambda_0 = 10^{-3}$

2. 计算 $J^T(\theta_t)$

3. 构造增量正规方程 $(J^T(\theta_t)J(\theta_t) + \frac{1}{\lambda}I)\delta\theta = J^T(\theta_t)(\mathbf{x} - f(\theta))$

4. 通过求解增量正规方程, 得到 $\delta(\theta)$

如果 $\|\mathbf{x} - f(\theta_t + \delta\theta)\|^2 < e^k$, 令 $\theta_{t+1} = \theta_t + \delta(\theta)$,

如果 $\|\delta(\theta)\| < \varepsilon$, 终止迭代;

否则令 $\lambda_{t+1} = 10\lambda_t$ $t = t + 1$, 执行第2步

否则 $\|\mathbf{x} - f(\theta_t + \delta\theta)\|^2 \geq e^k$, 令 $\lambda_{t+1} = 0.1\lambda_t$, 执行第3步。

Coding


阅读task-2/task2-3_test_lm_optimization.cc的代码流程，归纳LM算法的流程，并写成伪代码。

Levenberg-Marquardt法--增量规方程的求解


对称、稀疏

$$\left(J^T(\theta_t)J(\theta_t) + \frac{1}{\lambda}I \right) \delta\theta = J^T(\theta_t)(x - f(\theta))$$

$$J(\theta_t) = [J_C J_X]$$



(a)
 $J^T(\theta)$



(b)
 $J^T(\theta)J(\theta)$

$$\begin{aligned} J^T(\theta_t)J(\theta_t) &= \begin{bmatrix} J_C^T J_C & J_C^T J_X \\ J_X^T J_C & J_X^T J_X \end{bmatrix} \\ &= \begin{bmatrix} J_{CC} & J_{CX} \\ J_{XC} & J_{XX} \end{bmatrix} \end{aligned}$$

Levenberg-Marquardt法--正规方程的求解

$$\left(J^T(\theta_t)J(\theta_t) + \frac{1}{\lambda}I\right)\delta\theta = J^T(\theta_t)(x - f(\theta))$$

$$\begin{aligned}\tilde{J}_{CC} &= J_{CC} + \frac{1}{\lambda}I_{CC} \\ \tilde{J}_{XX} &= J_{XX} + \frac{1}{\lambda}I_{XX}\end{aligned}$$

$$\begin{bmatrix} \tilde{J}_{CC} & J_{CX} \\ J_{XC} & \tilde{J}_{XX} \end{bmatrix} \begin{bmatrix} \delta_C \\ \delta_X \end{bmatrix} = \begin{bmatrix} b_C \\ b_X \end{bmatrix}$$

左乘 $\begin{bmatrix} I & -J_{CX}\tilde{J}_{XX}^{-1} \\ 0 & I \end{bmatrix}$

Schur补

$$\begin{bmatrix} \tilde{J}_{CC} - J_{CX}\tilde{J}_{XX}^{-1}J_{XC} & 0 \\ J_{XC} & \tilde{J}_{XX} \end{bmatrix} \begin{bmatrix} \delta_C \\ \delta_X \end{bmatrix} = \begin{bmatrix} b_C - J_{CX}\tilde{J}_{XX}^{-1}b_X \\ b_X \end{bmatrix}$$

$$\begin{cases} (\tilde{J}_{CC} - J_{CX}\tilde{J}_{XX}^{-1}J_{XC})\delta_C = b_C - J_{CX}\tilde{J}_{XX}^{-1}b_X \\ \tilde{J}_{XX}\delta_X = b_X - J_{XC}\delta_C \end{cases}$$

线性方程，共轭梯度法求解

Jacobian矩阵的计算

以第 i 个三维点在第 j 个相机中的投影为例

$$e_{ij} = \frac{1}{2} \|\mathbf{e}_{ij}\|^2 = \frac{1}{2} \|\hat{\mathbf{u}}_{ij} - \mathbf{u}_{ij}(\mathbf{C}_j, \mathbf{X}_i)\|^2 = \frac{1}{2} \left((\hat{u}_{ij} - u_{ij}(\mathbf{C}_j, \mathbf{X}_i))^2 + (\hat{v}_{ij} - v_{ij}(\mathbf{C}_j, \mathbf{X}_i))^2 \right)$$

$$\xi_{ij} = \begin{bmatrix} \mathbf{C}_j \\ \mathbf{X}_i \end{bmatrix}, \quad \mathbf{C}_j = (f_j, k_1, k_2, \mathbf{R}_j, \mathbf{t}_j)$$

详细过程见参考文件BAJacobian矩阵推导.pdf

$$\frac{\partial e_{ij}}{\partial \xi_{ij}^T} = \mathbf{e}_{ij}^T \frac{\partial \mathbf{e}_{ij}}{\partial \xi_{ij}^T} = -\mathbf{e}_{ij}^T \frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \xi_{ij}^T}$$

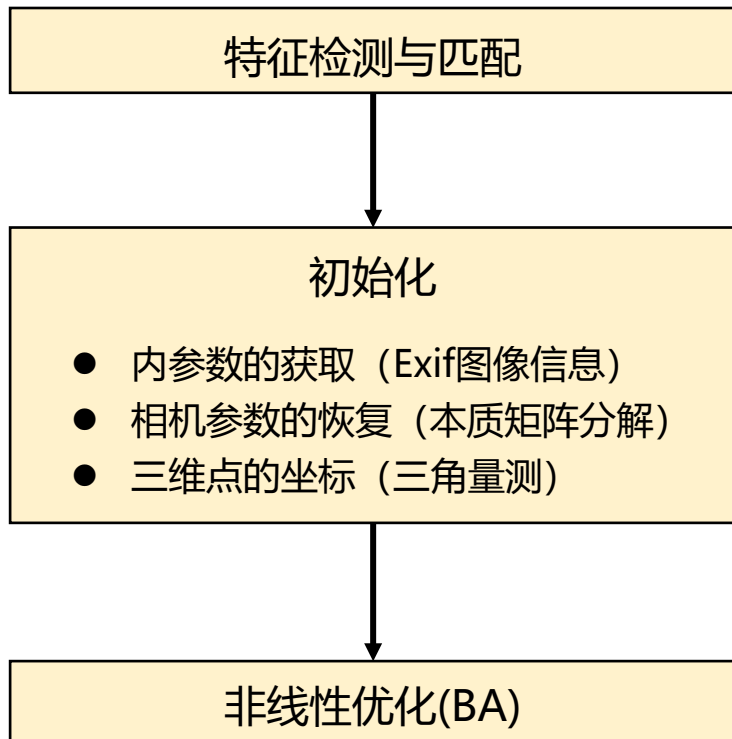
$$\frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \xi_{ij}^T} = \begin{bmatrix} \frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \mathbf{C}_j^T} & \frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \mathbf{X}_i^T} \end{bmatrix}$$

$$= \begin{bmatrix} \frac{\partial u_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{C}_j^T} & \frac{\partial u_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{X}_j^T} \\ \frac{\partial v_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{C}_j^T} & \frac{\partial v_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{X}_j^T} \end{bmatrix}$$

Coding

仔细推导Jacobian矩阵，并完成task2/task2-4_test_jacobian.cc中Jacobian矩阵的实现。

理解->推导->实现== 真正掌握



Coding

阅读task2/task2-5_test_bundle_adjustment.cc中，熟悉两视角的BA原理和流程。

理解->推导->实现== 真正掌握

感谢聆听 !
Thanks for Listening